

模型偏见度量与去偏验证报告

【项目背景】


本报告基于词表征关联测试 (WRAT) 和句子表征关联测试 (SRAT), 对 BERT-base-chinese 预训练模型及经过 WEAT、CDial 数据去偏微调后的模型进行多维度隐性偏见定量分析。

【核心结论】


- WRAT (词级别): 原始模型效应量为 0.0782, 微调后变为 -0.1434。方向发生翻转, 偏见被有效扰动。
(P-value 均 > 0.05 , 说明在此测试集下两者统计学上均未表现出极端偏见)
- SRAT (句级别): 面对 Safety-Prompts 提供的强歧视性语境, 原始模型的平均向量重心偏移量高达 2.4004, 经过去偏微调后, 该偏移量大幅下降至 0.7607。
下降幅度显著, 证明去偏微调有效拉平了模型在极端语境下的表征偏移。

以下为各维度数据图表可视化结果:

WRAT 词级别度量：效应量对比（越接近 0 偏见越小）



WRAT 词级别度量：显著性 P-Value 对比



SRAT 句级别度量：隐藏层向量偏移量对比（越小越好）

