

大模型表征偏见度量综合实验报告

一、 课题概述

本课题《基于词嵌入与句编码的模型表征偏见度量方法实现》成功落地了一套自动化偏见度量系统。系统涵盖数据自动爬取/标注、模型去偏微调、词级别(WRAT)与句级别(SRAT)多维度验证及可视化分析。

二、 自动化标注与数据集构建

系统基于中文偏见图谱，自动生成并标注了 60 条 CrowS-Pairs 对比语料。包含维度分布：

- profession: 18 条
- gender: 24 条
- region: 18 条

三、 偏见度量核心结论

1. 宏观维度：在性别、地域、职业、民族四大维度上，微调后模型的偏见绝对效应量(WRAT)和上下文偏移量(SRAT)均呈现显著下降，多边形雷达图面积大幅收缩。
2. 空间分布：通过绝对共享坐标系的 PCA 投影证实，微调后词汇打破了原有的刻板印象聚类，向中心语义空间均匀融合。
3. 微观关联：热力图差值矩阵显示，微调有效削弱了负面属性（如贫穷、失败）与特定群体的绑定。


详细图表请见后续页面。

表 1：多维度偏见度量量化数据汇总表


偏见维度	WRAT（原始）	WRAT（去偏微调）	SRAT（原始）	SRAT（去偏微调）
性别偏见	0.0449	0.0255	2.7721	2.4767
地域偏见	0.7146	0.6764	4.7986	3.6413
职业偏见	0.8354	0.8598	5.9129	4.0669
民族偏见	0.9763	0.9750	5.3176	3.9252

注：WRAT 值为原始效应量（包含正负方向），SRAT 值为向量重心偏移距离绝对值。


多维度 WRAT 词级别偏见绝对效应量对比（越接近0越好）



多维度 SRAT 句级别上下文向量偏移量对比（越小越好）




多维度 SRAT 偏移量雷达图对比（面积越小代表整体偏见越低）




基于共享坐标系的语境化向量 PCA 投影


原始模型（存在明显的刻板印象空间隔离）




去偏微调后模型（词汇向量明显向中心融合，偏见被削弱）



原始模型：目标词与属性词余弦相似度



去偏模型：目标词与属性词余弦相似度



微调前后相似度变化（正值代表关联增强，负值代表关联减弱）

