

图1：多维度 WRAT 词级别偏见绝对效应量对比（越接近0越好）




图2：多维度 SRAT 句级别上下文向量偏移量对比（越小越好）





图3：基于共享坐标系的语境化向量 PCA 投影

原始模型（存在明显的刻板印象空间隔离）



去偏微调后模型（词汇向量明显向中心融合，偏见被削弱）

