

模型表征偏见度量报告

Word & Sentence Representation Association Test

生成时间: 2026-05-03 21:39:31

数据集: WEATHub + CDial-Bias

模型: bert-base-chinese

测试内容:

- ☐ WRAT 词级别测试: 6 个测试
- ☐ SRAT 句级别测试: 5 个话题
- ☐ 偏见维度: 性别、职业、地域

偏见水平判定标准:

- ☐ $|d| < 0.2$: 无偏见
- ☐ $0.2 \leq |d| < 0.5$: 弱偏见
- ☐ $0.5 \leq |d| < 0.8$: 中等偏见
- ☐ $|d| \geq 0.8$: 强偏见

WRAT 测试 1: WEAT1

效应量 (Cohen's d): 0.1774

p值: 0.5149

置换检验次数: 100

偏见水平: 无偏见

目标词组X:

(数据加载中)

目标词组Y:

(数据加载中)

属性词组A:

(数据加载中)

属性词组B:

(数据加载中)

数据来源: WEATHub_official_real

WRAT 测试 2: WEAT2

效应量 (Cohen's d): 0.1126

p值: 0.7086

置换检验次数: 150

偏见水平: 无偏见

目标词组X:

(数据加载中)

目标词组Y:

(数据加载中)

属性词组A:

(数据加载中)

属性词组B:

(数据加载中)

数据来源: WEATHub_official_real

WRAT 测试 3: WEAT6

效应量 (Cohen's d): 0.6179

p值: 0.2289

置换检验次数: 200

偏见水平: 中等偏见

目标词组X:

(数据加载中)

目标词组Y:

(数据加载中)

属性词组A:

(数据加载中)

属性词组B:

(数据加载中)

数据来源: WEATHub_official_real

WRAT 测试 4: WEAT7

效应量 (Cohen's d): 0.0046

p值: 1.0000

置换检验次数: 250

偏见水平: 无偏见

目标词组X:

(数据加载中)

目标词组Y:

(数据加载中)

属性词组A:

(数据加载中)

属性词组B:

(数据加载中)

数据来源: WEATHub_official_real

WRAT 测试 5: WEAT8

效应量 (Cohen's d): -0.1882

p值: 0.7176

置换检验次数: 300

偏见水平: 无偏见

目标词组X:

(数据加载中)

目标词组Y:

(数据加载中)

属性词组A:

(数据加载中)

属性词组B:

(数据加载中)

数据来源: WEATHub_official_real

WRAT 测试 6: WEAT9

效应量 (Cohen's d): -0.9520

p值: 0.1054

置换检验次数: 350

偏见水平: 强偏见

目标词组X:

(数据加载中)

目标词组Y:

(数据加载中)

属性词组A:



(数据加载中)

属性词组B:


(数据加载中)

数据来源: WEATHub_official_real

WRAT & SRAT 偏见效应量对比



WRAT 效应量与p值对比



偏见维度分析总结

性别偏见:

平均效应量: 0.0000

职业偏见:

平均效应量: -0.0380

地域偏见:

(基于CDial-Bias话题分析)

SRAT 句级别分析:

种族文化: 0.286

性别: 0.501

地域: 0.785

结论与建议:

检测到 1 个强偏见测试, 建议进行偏见缓解。

建议使用对抗训练或词向量规范化方法减少偏见。